

1차 실험 보고서

Gemma2:2B 4,000개 학습 실험

한국어 영수증 OCR · QLoRA · 재무 Excel 자동화 비교 평가

항목	내용
평가 일자	2026-08-19
평가 데이터	한국어 영수증 17건 (receipt_kr.json)
비교 모델	gemma2:2b / gemma2-no-category / gemma2-yes-category
평가 방식	순수 모델 결과 + 규칙 보정·Excel 생성 후 최종 시스템 결과
총 호출	17건 × 3개 모델 = 51회

핵심 결론 현재 평가에서는 기본 gemma2:2b가 최종 정확도 36.76%로 1위였다. 다만 이 수치는 품목 중심·업적 일치 평가에 크게 좌우되며, yes 모델이 목표로 한 카드사·승인번호·마스킹 카드번호·공급가액·부가세 능력은 현재 정답 데이터로 충분히 측정되지 않았다.

1. 실험 목적과 시스템 구성

본 실험의 목적은 기본 Gemma2:2B와 4,000개 학습 데이터로 만든 두 QLoRA 어댑터를 동일한 한국어 영수증 OCR 입력에 적용하고, 순수 모델 추출 성능과 실제 Excel 문서화 시스템 성능을 분리해 비교하는 것이다.

1.1 비교 모델

모델	역할	주요 의도
gemma2:2b	기준 모델	별도 미세조정 없는 Ollama 기본 모델
gemma2-no-category	QLoRA 이전/대조 모델	카테고리 정보 강조 전 학습 모델
gemma2-yes-category	QLoRA 신규 모델	결제수단, 카드정보, 공급가액·부가세·합계 등 Excel 입력 핵심 값 강화

1.2 실행 구조

평소 개발 환경에서는 프론트엔드를 npm으로, 백엔드와 OCR 서비스를 각각 로컬 가상환경의 uvicorn(8000, 8001 포트)으로 실행했다. 이 경우 LLM 호출은 Docker가 아니라 Windows 로컬 Ollama(127.0.0.1:11434)를 사용한다.

- OCR: 로컬 OCR 서비스가 이미지에서 텍스트와 근거 영역을 추출
- LLM: 동일 OCR 텍스트를 세 모델에 각각 전달하여 JSON 생성
- 최종 시스템: 날짜·금액 규칙 보정과 정규화 적용
- Excel: Python openpyxl 기반 finance_workbook_service가 4종 재무 양식 생성

환경 구분 로컬 백엔드는 로컬 Ollama를 사용한다. Docker Compose 백엔드는 Docker 내부의 ollama:11434를 사용하며 두 Ollama의 모델 저장소는 서로 독립적이다.

2. 평가 설계

2.1 평가 데이터

receipt_kr.json은 17건의 영수증에 대해 가게명, 구매일자, 구매물품, 총 물품 수량, 총 결제액, 결제방식, 할부 여부를 제공한다. 이미지 파일명이 JSON에 포함되어 있지 않아 0~16번 순서로 이미지와 정답을 연결했다.

2.2 순수 모델과 최종 시스템

구분	포함 단계	해석
순수 모델	OCR 텍스트 → LLM JSON	미세조정 모델 자체의 구조화 능력
최종 시스템	LLM JSON → 규칙 보정 → 정규화 → Excel	실제 서비스에서 사용자가 받는 값

2.3 현재 점수 구성

각 모델은 총 204개 필드로 평가되었다. 일반 필드 84개와 30개 품목의 4개 하위 필드(품목명·수량·단가·금액) 120개로 구성된다. 품목 평가가 전체의 58.8%를 차지한다.

해석 주의 현재 정확도는 공백·특수문자·OCR 유사문자 차이도 오답으로 처리하는 엄격 일치 점수다. 품목은 배열 순서대로 비교되어 한 행이 추가되거나 누락되면 뒤 행까지 연쇄 오답이 될 수 있다.

3. 17건 전체 결과

모델	순수	최종	최종 정답	완전 정답	평균 응답
gemma2:2b	37.25%	36.76%	75/204	0/17	46.42초
gemma2-no-category	19.61%	20.10%	41/204	0/17	33.39초
gemma2-yes-category	14.22%	16.18%	33/204	0/17	33.95초

기본 gemma2:2b가 최종 시스템 정확도 36.76%로 가장 높았다. no-category는 기본 모델보다 16.66%p, yes-category는 20.58%p 낮았다. 반면 학습 모델들의 평균 응답시간은 기본 모델보다 약 12~13초 짧았다.

3.1 최종 시스템 필드별 정확도

필드	기본	no-category	yes-category
결제일	88.2%	88.2%	70.6%
합계금액	76.5%	76.5%	76.5%
상호명	41.2%	17.6%	23.5%
결제방식	5.9%	0%	5.9%
카테고리	0%	0%	0%
품목명	10.0%	6.7%	3.3%
품목 수량	60.0%	13.3%	0%
품목 단가	20.0%	10.0%	3.3%
품목 금액	40.0%	3.3%	3.3%

3.2 구조적 오류

- no-category는 17건 중 15건에서 items가 없거나 빈 배열이었다.

- yes-category는 17건 모두에서 items가 없거나 빈 배열이었다.
- yes-category는 17건 모두 document_type 대신 doc_type을 반환했다.
- 세 모델 모두 LLM 호출과 Excel 파일 생성에는 17/17건 성공했다.

중요 Excel 생성 성공은 파일이 열리고 예상 시트가 활성화되었다는 뜻이다. 행 수와 셀 값이 정답이라는 뜻은 아니다.

4. 정확도가 낮은 원인

4.1 평가 목적과 정답 데이터의 불일치

yes 모델은 카드/현금 구분, 카드사, 마스킹 카드번호, 승인번호, 공급가액, 부가세, 합계금액을 잘 인식하도록 학습했지만 receipt_kr.json에는 카드사·승인번호·공급가액·부가세가 독립 정답 필드로 존재하지 않는다. 현재 직접 평가되는 yes 모델 핵심 필드는 결제방식 17개와 합계금액 17개, 총 34개로 전체 204개 중 약 16.7%에 불과하다.

4.2 품목 중심 가중치

품목 필드가 전체 점수의 58.8%를 차지한다. 품목을 전혀 출력하지 않으면 나머지 일반 필드를 모두 맞혀도 이론적 최고점은 약 41.2%다. 따라서 결제정보 특화 모델을 품목 중심 전체 점수로 평가하는 것은 불공정하다.

4.3 업적 일지와 순서 비교

‘★LG 34UC79G. BKR(한)’과 ‘LG 34UC79G.BKR(한)’처럼 의미상 동일하거나 OCR 오차로 설명 가능한 차이도 오답이다. ‘카드(3562**153*)’와 ‘CARD’도 결제수단 종류는 맞지만 전체 문자열이 다르므로 오답이다.

4.4 학습·서비스 스키마 불일치

현재 서비스는 document_type과 items 배열을 요구한다. yes 모델이 doc_type을 일관되게 반환하고 items를 전부 생략한 것은 단순 학습 부족보다는 학습 정답 형식이 서비스 프론트와 다르다는 강한 신호다. doc_type 문제와 items 누락은 별개의 문제이며 키 이름만 고친다고 품목이 자동으로 복구되지는 않는다.

4.5 어댑터 배포 방식

어댑터는 google/gemma-2-2b-it 기반으로 학습했고, Ollama에서는 Q4_0 양자화된 gemma2:2b에 직접 결합했다. 베이스 체크포인트와 양자화 방식의 차이가 품질 저하를 일으킬 가능성이 있다. 정확한 원본 베이스에 어댑터를 병합한 뒤 GGUF로 변환한 모델과 비교할 필요가 있다.

5. OCR 영향과 분리 평가

OCR 성능 부족은 일부 오류에 영향을 주었을 가능성이 있다. 상품명에 글자 변형, 불필요한 단어를 품목으로 추가한 사례가 그 상황이다. 그러나 현재 평가 내보내기에는 모델에 전달된 전체 OCR 원문과 필드별 OCR confidence가 포함되지 않아 OCR의 기여도를 정량화할 수 없다.

비교 입력	결과 해석
실제 OCR 텍스트	현재 전체 파이프라인 성능
사람이 전사한 깨끗한 텍스트	OCR 영향을 제거한 LLM 추출 성능
두 입력의 차이	OCR로 인한 손실량

- 깨끗한 텍스트에서는 맞고 OCR에서 틀리면 OCR 문제다.
- 두 입력에서 모두 틀리면 LLM 학습 또는 스키마 문제다.
- OCR에 값 자체가 없으면 모델이 복원할 근거가 없으며, 임의 복원은 환각이다.

날짜와 합계금액 점수가 높은 이유도 LLM만의 성능으로 해석하면 안 된다. 최종 시스템은 정규식 기반 `_receipt_hints()`로 날짜와 금액을 보정한다.

6. Excel 신뢰성 평가

6.1 현재 확인된 범위

현재 Excel 검증은 파일 생성, 4개 시트 존재, 예측 유형에 해당하는 시트 활성화 확인한다. 실제 데이터 행 수, 셀 내용, 누락과 환각은 확인하지 않는다. 특히 구매요청서 행 수는 items 배열에 의존하므로 학습 모델의 품목 누락은 Excel 행 누락으로 직결될 수 있다.

6.2 다음 평가에서 필요한 셀 지표

지표	정의
대상 셀	정답상 값이 들어가야 하는 동적 데이터 셀
채움률	채워진 필수 셀 ÷ 값이 필요한 정답 셀
셀 정확도	정확한 셀 ÷ 비교 대상 셀
입력 정밀도	정확한 입력 셀 ÷ 모델이 채운 셀
입력 재현율	정확한 입력 셀 ÷ 값이 필요한 정답 셀
환각률	정답은 null인데 불필요하게 채운 셀 비율
행 정확도	정답 품목 수와 Excel 데이터 행 수의 일치

정답도 null이고 셀도 빈 경우는 정상 공란이다. 필수 값인데 비어 있으면 누락이고, 정답이 null인데 값이 들어가면 환각이다. 정적 제목·결재란·빈 템플릿 시트는 평가 대상 셀에서 제외해야 한다.

6.3 신뢰도 산정

LLM이 스스로 출력한 확률을 그대로 신뢰해서는 안 된다. 필드 신뢰도는 OCR 근거, 모델 간 합의, 규칙 검증, 실제 검증 세트 정확도를 결합하고 검증 데이터로 보정해야 한다.

- OCR 근거: 값이 OCR 텍스트와 bbox에 존재하며 OCR confidence가 충분한가
- 모델 합의: 세 모델이 동일한 값을 냈는가
- 규칙 검증: 공급가액 + 부가세 = 합계, 수량 × 단가 = 품목 금액인가

- 실측 신뢰도: 별도 검증 세트에서 해당 컬럼의 실제 정확도가 얼마인가

권장 출력 문서별로 대상 셀·채운 셀·정답·오답·누락·환각 수와 컬럼별 정확도를 제공하고, 신뢰도는 높음/보통/낮음과 그 근거를 함께 표시한다.

7. yes 모델 목표에 맞는 평가 스키마

결제정보 특화 능력을 검증하려면 정답 데이터를 다음처럼 분리해야 한다. 원본에 값이 없으면 키를 생략하지 않고 null을 사용해야 환각도 측정할 수 있다.

영역	권장 필드
기본	merchant, transaction_date, transaction_time
결제	payment_method_type, card_company, masked_card_number, approval_number, installment
금액	supply_amount, tax_amount, total_amount, currency
업무 분류	document_type, expense_category
품목	items[].name, quantity, unit_price, supply_amount, tax_amount, total_amount

현재 서비스 프롬프트도 card_company, masked_card_number, approval_number, installment 등을 독립 키로 요구하지 않으며, Excel 양식에도 이 값들의 독립 열이 없다. 평가 데이터뿐 아니라 프롬프트, 저장 스키마, Excel 열 매핑까지 같은 구조로 맞춰야 실제 업무 성능을 검증할 수 있다.

8. 추가 학습과 모델 크기 판단

8.1 4,000개·1 epoch의 의미

현재 오류는 학습량 부족보다 학습 목표와 서비스 스키마 불일치 신호가 더 강하다. 잘못된 키와 누락 구조를 가진 데이터로 epoch만 늘리면 잘못된 형식을 더 강하게 학습할 수 있다.

- 스키마와 프롬프트를 먼저 통일한다.
- 학습·검증·테스트 세트를 분리하고 17건은 학습에 포함하지 않는다.
- 동일 데이터로 1·2·3 epoch 체크포인트를 저장해 validation loss와 필드 성능을 비교한다.
- JSON 파싱 성공률, 필수 키 존재율, items 생성률, 환각률을 함께 본다.

8.2 Gemma 3 4B 가능성

Gemma 3 4B는 더 높은 표현력과 지시 준수 능력으로 복수 품목과 한국어 OCR 노이즈 처리에서 개선될 가능성이 있다. 그러나 현재 Gemma2 어댑터를 재사용할 수 없고, 데이터 스키마가 틀리면 더 큰 모델도 같은 오류를 학습한다. 먼저 Gemma2 2B 파이프라인을 바로잡은 뒤 동일 조건으로 4B를 비교해야 모델 크기 효과를 분리할 수 있다.

9. 권고 실행계획

단계	작업	완료 기준
1	정답·서비스·Excel 스키마 통일	모든 학습 샘플이 document_type과 전체 키를 일관되게 포함
2	결제정보 전용 정답 보강	카드사·승인번호·마스킹 번호·공급가액·부가세를 null 포함 독립 필드화
3	평가 개선	업적/정규화 점수 분리, 품목 순서 독립 매칭, 목적별 점수 제공
4	OCR 영향 분리	OCR 원문·confidence 저장 및 깨끗한 전사문 대비 성능 산출
5	Excel 셀 검증	행·셀 단위 정답/오답/누락/판각과 컬럼별 신뢰도 산출
6	배포 방식 비교	직접 어댑터 방식과 원본 베이스 병합 - GGUF 방식 비교
7	재학습	1·2·3 epoch 검증 곡선과 독립 테스트 결과 확보
8	4B 비교	수정된 동일 데이터·프롬프트로 2B 대비 비용/성능 비교

10. 최종 총평

이번 1차 실험은 학습 모델이 기본 모델보다 낮은 전체 점수를 냈다는 사실뿐 아니라, 현재 평가가 yes 모델의 결제정보 특화 목표를 충분히 측정하지 못하고 있다는 점을 확인했다는 데 의미가 있다. Excel 파일은 17건 모두 생성됐지만, 이는 구조적 생성 성공일 뿐 셀 내용의 정확성을 보증하지 않는다.

즉시 서비스 기본 모델을 교체하기보다는 gemma2:2b를 유지하고, 결제정보 중심 정답 스키마와 Excel 셀 단위 평가를 먼저 구축하는 것이 타당하다. 이후 동일 프롬프트·동일 스키마·정확한 베이스 병합 조건으로 Gemma2 2B를 재학습하고, 성능 개선이 확인된 다음 Gemma 3 4B 확장을 검토해야 한다.

의사결정 현재 학습 모델은 연구 후보로 유지하되 운영 기본 모델로 승격하지 않는다. 다음 실험의 성공 기준은 전체 점수 하나가 아니라 결제정보 추출 정확도, 품목 성능, OCR 독립 성능, Excel 셀 정확도와 환각률을 각각 개선하는 것이다.

부록 A. 실험 산출물

산출물	설명
finance-model-evaluation-combined-17.json	17개 영수증 × 3개 모델의 누적 원본 결과와 통계
receipt_kr.json	현재 평가에 사용한 한국어 영수증 구조화 정답
재무 모델 평가 페이지	세 모델의 순수·최종 결과 및 필드 비교 화면
4종 Excel 양식	경비지출결의서, 출장여비교통비정산서, 구매품의요청서, 복리후생비신청서